

HealthSearch — Motor de Busca Híbrido (BM25 + Semântico + RRF)


Autor: PEDRO HENRIQUE BENICIO DE OLIVEIRA — RGM: 33602697

Relatório técnico • UNIPÊ — Tendências em Ciência da Computação

1. Arquitetura da solução

O aplicativo Streamlit (**healthsearch_app.py**) segue quatro fases. **(1) Pré-processamento:** minúsculas, remoção de acentos e caracteres especiais, stopwords em português; códigos como *CÓD-ECG-12D* são mantidos como token único e também divididos em partes. **(2) BM25:** Okapi BM25 (rank_bm25) recalculado a cada movimento dos sliders k (0–3, padrão 1,2) e b (0–1, padrão 0,75). **(3) Semântico:** embeddings *paraphrase-multilingual-MiniLM-L12-v2* normalizados; similaridade de cosseno entre consulta e documentos, com simulação vetorial documentada (bag-of-concepts) como contingência offline. **(4) RRF:** Score = $\alpha \cdot 1/(60 + \text{rank_BM25}) + (1 - \alpha) \cdot 1/(60 + \text{rank_sem})$, com α ajustável. A interface tem abas Léxico, Semântico, Híbrido RRF e Matriz Comparativa; o bônus aplica Cross-Encoder (ms-marco-MiniLM-L-6-v2) sobre o Top-3 híbrido, exibindo a variação de posição.

2. Comparação de ranks



A busca por *ataque cardíaco* não compartilha tokens com o corpus (que usa "infarto" e "síndrome coronariana"): todos os scores BM25 são 0 e a ordem é mero desempate, enquanto o semântico já ordena por proximidade de significado. Para *CÓD-ECG-12D* o BM25 recupera exatamente os Docs 1 e 6 (scores $\approx 2,4$ e $2,3$; demaiss 0), ao passo que o semântico distribui a similaridade por documentos cardíacos genéricos. Documentos com BM25 = 0 não contribuem com a parcela léxica do RRF, evitando que um desempate arbitrário influencie a fusão. Em *AAS 100mg* a sigla não aparece no corpus (que usa "ácido acetilsalicílico"): o BM25 é cego e o modelo semântico é limitado, o que ilustra a necessidade de expansão de sinônimos ou de um modelo clínico em português. O RRF combina os sinais sem normalizar scores.

3. Observações

- k alto valoriza repetição de termos; b alto penaliza documentos longos — com apenas 6 documentos curtos o efeito é pequeno, mas visível nos scores.
- $\alpha=1$ reproduz o BM25 e $\alpha=0$ o semântico, servindo de diagnóstico.
- O RRF usa apenas posições, portanto é robusto à diferença de escala entre scores BM25 (não limitado) e cosseno (−1 a 1).

4. Divisão de tarefas da equipe

Integrante	Responsabilidade
PEDRO HENRIQUE BENICIO DE OLIVEIRA — RGM: 33602697	Fase 1: Pré-processamento e sliders
Aluno 2	Fase 3: embeddings, cosseno e bônus Cross-Encoder
Aluno 3	Fase 4: RRF, interface em abas e relatório

Substitua "Aluno 1/2/3" pelos nomes da equipe.